

INTENSIVÃO QUANT AI ▪ IMPACT UFSCAR

Aula 02 — Dados

Coleta, Limpeza e Preparação de Dados Financeiros

Felipe Maldonado

VP Diretoria Quant ▪ Impact UFSCAR

Intensivão Quant AI 2025

Teoria (30 min)

- O universo IBOVESPA: composição e rebalanceamento
- Pipeline de dados: da fonte ao parquet
- Tratamento de outliers e dados faltantes
- Retornos compostos vs simples

Código (70 min)

- `baixar_dados()` — `yfinance` → `DataFrame`
- `limpar_precos()` — outliers, forward-fill
- `calcular_retornos_mensais()` — `resample` + `log-ret`
- Salvar 3 parquets base
- Verificação de sanidade dos dados

O Universo IBOVESPA

- Índice de retorno total da B3: 90 ativos
- Critério de inclusão: liquidez ($VDLA \geq 0,1\%$ do total)
- Rebalanceamento: janeiro, maio e setembro
- Composição histórica obtida via yfinance
- Período de análise: 2015–2024 (120 meses)


Por que o IBOVESPA?

- Universo amplo o suficiente para cross-section
- Dados históricos de qualidade disponíveis
- Relevante para o Desafio Itaú
- Benchmark natural para estratégias Long Only

Atenção: Survivorship Bias

- yfinance retorna composição atual + histórico de preços

Pipeline de Dados



Outlier Detection

Retorno diário $|r_t| > 3\sigma$ rolling 60d $\Rightarrow$
substituído por NaN
Forward-fill limitado a 5 dias
consecutivos

Retorno Composto Mensal

$$r_{\text{mês}} = \prod_{t \in \text{mês}} (1 + r_t) - 1$$

Equivalente a

`resample('ME').apply(retorno_compos`

O que Vamos Construir

Funções a implementar

- `baixar_dados(tickers, start, end) → DataFrame` de preços
- `limpar_precos(df) → DataFrame` limpo, outliers removidos
- `calcular_retornos_mensais(precos) → DataFrame` mensal
- `verificar_sanidade(df) →` estatísticas de qualidade

Entradas (parquets)

- Nenhum (download direto via yfinance)

Saídas (parquets)

- `precos_ibov.parquet`
- `retornos_diarios_limpo.parquet`
- `retornos_mensais_limpo.parquet`

Referências

- **Cont, R.** (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- **Harvey, C. et al.** (2016). ... and the cross-section of expected returns. *RFS*, 29(1), 5–68.
- **yfinance** (2019). Yahoo Finance Python wrapper. *GitHub*: [ranaroussi/yfinance](#).
- **Mussa, A. et al.** (2012). Hipótese de mercados eficientes e finanças comportamentais. *REGE*, 19(2).